

BACHELORARBEIT

Kooperative Neuroevolution in RoboCup2D

Alexander Isenko

Entwurf vom 28. Oktober 2016



BACHELORARBEIT

Kooperative Neuroevolution in RoboCup2D

Alexander Isenko

Aufgabensteller: Prof. Dr. Claudia Linnhoff-Popien

Betreuer: Thomas Gabor, M.Sc
Lenz Belzner, Dipl.-Medieninf.

Abgabetermin: 11. November 2016



Hiermit versichere ich, dass ich die vorliegende Bachelorarbeit selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe.

München, den 11. November 2016

.....
(*Unterschrift des Kandidaten*)

Abstract

Wir untersuchen in dieser Bachelorarbeit verschiedene Ansätze zur Entwicklung von neuronalen Netzen am Beispiel der Cross Entropy Method, genetische Algorithmen und Co-SyNE unter Einschränkung von spärlichen Fitnesssignalen, hochdimensionalen kontinuierlichen Zustandsräumen und simulationsbasierter Optimierung.

Der Suchraum wird durch diskrete Cosinustransformationen (DCT) unter der Annahme reduziert, dass benachbarte Gewichte zueinander korreliert stehen. Die Domäne ist ein Fußballsimulator, Half Field Offense (HFO), der Teams aus dem weltweiten Wettbewerb RoboCup zum Vergleichen bereitstellt. Die Implementierung erfolgt in Haskell und Python.

Inhaltsverzeichnis

1. Einführung	1
1.1. Aufgabenstellung	1
1.2. Motivation	1
1.3. Aufbau der Arbeit	1
2. Definitionen	3
2.1. Genetische Algorithmen	3
2.1.1. Individuen	4
2.1.2. Simulation	5
2.1.3. Selektion	5
2.1.4. Kreuzung	5
2.1.5. Mutation	6
2.1.6. Repopulation	7
2.2. Neuroevolution	8
2.2.1. Neuronale Netze	8
2.2.2. Verbindung mit genetischen Algorithmen	8
2.3. Diskrete Cosinus Transformation - DCT	8
2.3.1. Kodierung des Suchraums	9
2.4. Cooperative Synapsen Neuroevolution - CoSyNE	9
2.4.1. Permutation	9
2.5. Cross Entropy	9
2.5.1. Normalverteilung	9
3. Umsetzung in RoboCup2D	11
3.1. Half Field Offense	11
3.1.1. Zustandsraum	11
3.1.2. Aktionsraum	12
3.1.3. Einschränkungen	12
3.2. Implementierung der Algorithmen	13
3.2.1. Wahrscheinlichkeitsverteilung von Aktionen	13
3.2.2. Cross Entropy mit DCT	14
3.2.3. Neuroevolution mit DCT	14
3.2.4. CoSyNE mit DCT	14
3.3. Resultate	14
3.3.1. 1v1	14
3.3.2. Vergleich	15

4. Diskussion	17
4.1. Anwendungsmöglichkeiten	17
4.2. Coevolutionärer Aspekt	17
4.3. Ausblick	17
4.3.1. Genetische Algorithmen	17
4.3.2. Aufbau des neuronalen Netzes	17
4.3.3. Cross Entropy	17
4.3.4. Aktionsraum	17
4.3.5. Multi-Agenten Systeme	17
4.4. Verwandte Felder	17
4.4.1. Implementierung für OpenAI Gym	18
4.4.2. Bestärkendes Lernen - Black Box RL	18
4.4.3. Convolutional neuronale Netze und CoSyNE	18
A. Appendix	19
A.1. Architektur	19
A.1.1. Haskell Server	19
A.1.2. Python Agent	19
A.1.3. Kommunikation	19
A.1.4. Parallelisierungsmöglichkeiten	19
A.2. Statistik	19
A.2.1. Lineares Laufzeit und Speicherkomplexität für Evaluation	20
A.2.2. Stabile Varianzfunktion	20
A.3. Problematiken	20
A.3.1. HFO Server	20
A.3.2. HFO Python Library	20

1. Einführung

Für viele Probleme benutzt man heutzutage neuronale Netze (zitat), zum Beispiel zur Klassifikation von Bildern mit **Convolutional Neural Nets** (MNIST) oder zur Generierung von Text mithilfe von **Recurrent Neural Nets** (karpathy.github.io/2015/05/21/rnn-effectiveness). Diese allgemeinen Klassifikatoren (zitat) werden mithilfe von Stochastic Gradient Descend **SGD** trainiert, einer Technik die es erlaubt Minima in der Graphlandschaft anzustreben. Andere Möglichkeiten wie man neuronale Netze trainieren kann fallen dabei aus dem Fokus. Manche Domänen erlauben uns jedoch nicht SGD zu benutzen und ich spreche in dieser Arbeit anderweitige Möglichkeiten an und untersuche sie auf ihre Nützlichkeit in Domänen mit spärlicher Fitness.

1.1. Aufgabenstellung

In dieser Arbeit beschäftige ich mich mit der Entwicklung von neuronalen Netzen mithilfe von genetischen Algorithmen für die Domäne **Half Field Offense**. Diese hat spärliche Fitnesssignale, einen hochdimensionalen kontinuierlichen Zustandsraum und hat keine Möglichkeit die perfekte Lösung für eine Situation zu ermitteln. Aus dem Vergleich zwischen den verschiedenen Implementierungen kann man den Nutzen für andere Domänen mit ähnlichen Einschränkungen erahnen.

1.2. Motivation

Im Siemens Praktikum bin ich das erste Mal mit genetischen Algorithmen in Kontakt gekommen. Dabei lernte ich dass viele Domänen mit denen man sich in der Industrie auseinandersetzt mit herkömmlichen Deep Learning Methoden nur aufwendig bis gar nicht lösbar sind. Oft wird als Teillösung **Fitness Engineering** betrieben, also die Anpassung des Rewardsignals wenn die Aufgaben von vielen Zeitschritten und kontinuierlichen Aktionsketten abhängen. Deshalb habe ich mich alternative Techniken zur Entwicklung von neuronalen Netzen untersucht.

1.3. Aufbau der Arbeit

Im Rahmen dieser Arbeit werden im Kapitel 2 die Grundlagen von Genetischen Algorithmen und deren Verknüpfung zu neuronalen Netzen und der Cross Entropy Method erklärt und anschaulich dargestellt. Kapitel 3 beschäftigt sich mit der Domäne, Parametrisierung der Algorithmen und der jeweiligen Resultate. Das Kapitel 4 gibt einen Ausblick in weitere Verbesserungsmöglichkeiten und legt verwandte Felder dar. Im Appendix wird die Implementierung vom gesamten System überschlagen, Problematiken angesprochen und Lehren die für eine zukünftige Arbeit gezogen werden können angesprochen.

2. Definitionen

Dieses Kapitel bietet Einblick in die Grundlagen von **Genetischen Algorithmen** im Zusammenhang mit **neuronalen Netzen** und der **Cross Entropy Method**. Außerdem werden einige Verbesserungen zu den naiven Methoden besprochen, wie die Reduzierung des Suchraums durch **Fouriertransformationen** und die Einführung von einer **kooperativen Evolution** durch Hinzufügen von einer neuen Methode zum GA.

2.1. Genetische Algorithmen

Ein genetischer Algorithmus, im folgenden als *GA* abgekürzt, ist ein Optimierungsverfahren, der meiner Meinung nach an natürlichen Feinden am Besten zu erklären ist. Wir stellen uns beispielsweise eine Gruppe Antilopen und einen Geparden vor.




Abbildung 2.1.: Illustration von einem Geparden und einer Antilope

Sei unser Gepard durch seine Geschwindigkeit den Antilopen überlegen, dann wird das Antilopenrudel über Zeit in ihrer Anzahl sinken. Dabei werden die langsamen Antilopen dem Geparden erlegen und die Schnelleren überleben. Dieser Schritt wird als **Selektion** bezeichnet. Diese werden sich fortpflanzen und mit hoher Wahrscheinlichkeit Antilopen-Babys bekommen die ähnlich schnell sind. Dieser Vorgang bezeichnet sich als **Kreuzung**. Die Überlebenswahrscheinlichkeit des Rudels wird dadurch erhöht und wir nennen diesen Parameter **Fitness**.

Jede Antilope, oder auch **Individuum** genannt, hat eine eigene Fitness, die es aber bei Geburt noch nicht weiß, da sie noch nie vor einem Geparden weglaufen musste. Erst nachdem sie einmal erfolgreich entwischt ist, können wir uns vorstellen wie was ihre Fitness ist.

2. Definitionen

Ganz selten wird ein Antilopen-Baby geboren das ein klein bisschen längere Beine hat als alle anderen, dabei hat solche Beine keiner in dem gesamten Rudel. Sie erlauben ihm schneller zu Laufen, aber leider hat diese Ausprägung nicht nur Vorteile, da die Standhaftigkeit darunter leidet. Dieser unerwartete Veränderung in den Kindern heißt **Mutation**.

Fassen wir zusammen, nachdem jede Antilope die nach dem Raubkatzenangriff überlebt und sich fortgepflanzt hat, bekommen wir hoffentlich wieder eine vollzähliges Rudel, das wir **Population** nennen. Nach all diesen Schritten fängt der Kampf um das Überleben wieder an und geht solange, bis sich entweder Antilopen entwickeln die dem Gepard ständig entkommen können, oder bis die gesamte Population ausstirbt.

Damit haben wir die wichtigsten Begrifflichkeiten von einem genetischen Algorithmus erklärt und kommen zu der Frage, wie wir ihn umsetzen.

2.1.1. Individuen

Ein Individuum besteht aus einer Kodierung, auch **Zustandsraum** genannt, die die aussagekräftigen Eigenschaften von ihm ausmachen. Für eine Antilope wäre beispielsweise die folgende Kodierung möglich.

Höchstgeschwindigkeit	$50 \frac{km}{h}$
Beinlänge	$47 cm$
Gewicht	$43 kg$
Alter in Jahren	12

Tabelle 2.1.: Kodierung einer Antelope

Die Aufgabe von unserem GA ist ein oder mehrere Individuen zu finden die es schaffen vor dem Geparden wegzulaufen. Da wir aber nicht wissen ob die vorgeschlagene Kodierung gut oder schlecht ist, müssen wir Antilopen mit zufälligen Ausprägungen erstellen und dann den Algorithmus arbeiten lassen.

Das schaffen wir indem wir Grenzen für die Kodierung festlegen und später zufällige Werte in diesen Rahmen ausprobieren.

Ausprägung	Minimaler Wert	Maximaler Wert
Höchstgeschwindigkeit	$40 \frac{km}{h}$	$80 \frac{km}{h}$
Beinlänge	$40 cm$	$65 cm$
Gewicht	$39 kg$	$63 kg$
Alter in Jahren	2	20

Tabelle 2.2.: Grenzen für die Kodierung

Für die Kodierung unseres Individuums eignet sich ein Array von Zahlen. Um die gesamte Population darzustellen würde ein 2-dimensionales Array reichen, wobei jedes Element ein einzelnes Individuum darstellt. (evtl Grafik)

2.1.2. Simulation

Nachdem wir unsere Population an Antilopen erstellt haben, müssen wir sie in eine Simulationsumgebung schicken, die ihre Fitness misst. In unserem Beispiel müssten wir eine Physiks simulation mit einem Geparden programmieren, die nach einer Zeitspanne zurückgibt welche Antilopen überlebt haben.

Die Komplexität der Simulation hat einen großen Einfluss darauf ob der GA eine Lösung finden kann. (*Grafik*)

2.1.3. Selektion

Nachdem die Simulation vorbei ist, bekommen wir eine Population von Antilopen die jeweils überlebt hat oder nicht. Da die Fitness ist in diesem Fall binär ist, sortieren wir das Rudel aller Antilopen absteigend, wobei das Überleben natürlich mehr wert ist.

Nach dem Sortieren müssen wir ein prozentualen Betrag wählen, wieviele Eltern wir aus der Population wählen. In unserer Implementierung nennen wir diesen Parameter α . (*Grafik*)

2.1.4. Kreuzung

Die guten Individuen wurden ausgewählt und können sich fortpflanzen. Dafür nehmen wir jeweils zwei Individuen und nehmen zufällig die Ausprägungen von jeweils dem Vater und der Mutter.

Ausprägungen
56 $\frac{km}{h}$
42 cm
51 kg
10

Tabelle 2.3.: Kodierung des Vaters

Ausprägungen
62 $\frac{km}{h}$
55 cm
49 kg
8

Tabelle 2.4.: Kodierung der Mutter

Ausprägungen
56 $\frac{km}{h}$
55 cm
49 kg
10

Tabelle 2.5.: Kodierung vom Kind Nr.1

Ausprägungen
62 $\frac{km}{h}$
42 cm
51 kg
8

Tabelle 2.6.: Kodierung vom Kind Nr.2

In unserem Beispiel haben wir die Kinder mit dem folgenden Python Code konstruiert.

2. Definitionen

```

vater = [56,42,51,10]
mutter = [62,55,49,8]
kind1 = []
kind2 = []
for i in range(kodierung.length):
    r = random.uniform(0,1)
    if (r > 0.5):
        kind1[i] = vater[i]
        kind2[i] = mutter[i]
    else:
        kind1[i] = mutter[i]
        kind2[i] = vater[i]

```

Diese Art und Weise zwei Individuen zu kreuzen nennt sich **n-point crossover**, weil wir die Kodierung an undefiniert vielen Stellen unterbrechen und wieder zusammensetzen. Es gibt noch andere Kreuzungsmethoden die eine feste Anzahl von Aufteilungen benutzen, wie **one-** oder **two-point crossover**.

Um einen Unterschied zwischen diesen Methoden zu erkennen, stellen wir uns vor dass das Alter in Zusammenhang mit der Höchstgeschwindigkeit steht, weil ältere Tiere nicht mehr die Leistung bringen können die sie mal gebracht haben. Wenn nun ein Kind gezeugt wird, dass in unserem Beispiel ein hohes Alter vererbt, bringt ihm die Höchstgeschwindigkeit nichts mehr. Deshalb wäre es besser, wenn diese Ausprägungen zusammen übernommen werden, weil dadurch eine höhere Fitness garantiert werden kann. Kreuzungsmethoden die die Kodierung nicht oft aufspalten verletzen diese Eigenschaft seltener als *n-point crossover*.

Es ist zu beachten dass je nach Implementierung nur eins der beiden Kinder weiter verwendet wird, weil dann die Repopulation einfach einfacher ist, die Varianz nicht zu stark gesenkt wird und keinerlei Information verloren geht, weil die Eltern in der Population die Kodierung weiter tragen.

2.1.5. Mutation

Nachdem die Kinder erstellt wurden, müssen wir die Kodierung der Individuen etwas verändern, damit die Varianz in der Gesamtpopulation erhöht wird. Das machen wir indem wir durch die Kodierung der Kinder durchgehen und jede Ausprägung mit einer geringen Wahrscheinlichkeit verändern. Diese nennen wir β .

Ausprägungen
62 $\frac{km}{h}$
42 <i>cm</i>
51 <i>kg</i>
8

Tabelle 2.7.: Kodierung vom Kind Nr.2

Ausprägungen
62 $\frac{km}{h}$
42 <i>cm</i>
45 <i>kg</i>
8

Tabelle 2.8.: Mutierte Kodierung vom Kind Nr.2

Der Python Code sieht hier folgendermaßen aus:

```
kinder = [k1, k2...]
beta   = 0.1
for i in range(kinder.length):
    for j in range(kodierung.length):
        if (r > beta):
            kinder[i][j] = sampleNewFrom(kodierung[j].range)
```

Dieser Schritt ist wichtig damit man die Möglichkeit hat aus lokalen Fitnessminimas rauszukommen, weil es schnell passieren kann dass sich über Generationen gleichwertige Ausprägungen weiterverbreiten, da sie die derzeit beste Lösung vorschlagen. Ohne Mutation würde der GA zu dieser Lösung konvergieren ohne Bessere in Betracht zu ziehen.

In manchen Fällen kann man die Mutation noch weiter parametrisieren indem man ein Veränderungsfaktor als Argument hinzufügt. Diese Technik benutzt man, wenn die Kodierung nicht trivialerweise verändert werden kann, da sonst bestimmte Eigenschaften verloren gehen. In Kapitel 3 wird genau so ein Fall besprochen, weil wir unsere Individuen durch eine Wahrscheinlichkeitsverteilung darstellen.

2.1.6. Repopulation

Die Eltern wurden ausgewählt, die Kindern gezeugt und mutiert, nun müssen wir die Population in eine Form bringen sodass die Simulation neu gestartet werden kann. Wir stellen das Problem wieder an einem Beispiel dar.

```
population = [i1,i2,...]           # population.length = 10
alpha      = 0.4
eltern     = selection(population, alpha) # eltern.length = 4
kinder     = crossover(eltern)        # kinder.length = 4
beta       = 0.1
mutkinder  = mutation(kinder, beta)   # mutkinder.length = 4

newpopulation = eltern + mutkinder    # newpopulation.length = 8
```

Man kann einfach erkennen dass uns zwei Individuen zum Neustart der Simulation fehlen. Dieses Problem kann man auf viele Weisen angehen, die ihre Vorteile und Nachteile haben.

Mehr Kinder erstellen

Es ist möglich während der Kreuzung solange Kinder zu erzeugen, bis die Population wieder ihre Ausgangsgröße angenommen hat. Ein Vorteil wäre, dass diese Individuen mit wahrscheinlich besseren Ausgangskodierungen starten als inherent Neue. Der Nachteil ist jedoch die gesenkte Varianz in der Population und die erhöhte Wahrscheinlichkeit zum Feststecken in einem lokalen Fitnessminima.

2. Definitionen

Nicht selektiere Individuen nachfüllen

Man kann die nicht benutzen Individuen aus der vorherigen Population zum Auffüllen benutzen, was sich aber nur dadurch begründen würde, wenn die Chance besteht dass sie in der erneuten Simulation besser abschneiden als bisher. Ansonsten nehmen sie einen Platz einem potenziell besseren Individuum weg.

Neue Individuen erstellen

In der unserer Implementierung haben wir uns für das Nachfüllen von inherent neuen Individuen entschieden, da dadurch die Varianz der Population angehoben wird und dadurch mehr Lösungen möglich sind. Ein Nachteil sind die Kinder die dadurch keinen Platz bekommen, aber da dadurch keine Information verloren geht ist es zu vernachlässigen.

2.2. Neuroevolution

“Neuroevolution beschäftigt sich mit der Verknüpfung von Genetischen Algorithmen und Neuronalen Netzen”

2.2.1. Neuronale Netze

“Neuronale Netze sind eine riesige Gleichung”

“Formel von Machine Learning zeigen”

“Backpropagation wird angesprochen aber nicht ausführlich erklärt”

Dense Ebene

“Kleines Beispielnetz aufmalen und durchrechnen”

LSTM Ebene

“Kleines Beispielnetz aufmalen und durchrechnen”

Softmax Ebene

“Erklärung bieten wieso es sowas gibt und was für eine Formel angewendet wird”

2.2.2. Verbindung mit genetischen Algorithmen

“Die Verknüpfung findet in der Kodierung von den Individuen statt - wir nehmen eine (naive) Darstellung von allen Gewichten” “Problematik -> Folgerung zu DCT”

2.3. Diskrete Cosinus Transformation - DCT

“Der Suchraum kann durch die sog. DCT auf beliebige Dimensionalität eingeschränkt werden, wenn bestimmte Annahmen getroffen werden können”

“Fouriertransformationen machen folgendes...”

“Es gibt eine Inverse die aus einem n-stelligen liste eine m-stellige macht, wo die Zahlen korelliert sind (Beispiele)”

2.3.1. Kodierung des Suchraums

“Die Kodierung besteht aus eine 20-stelligen Liste wie im Paper (Cosyne), wo damit 2k Gewichte entwickelt wurden”

2.4. Cooperative Synapsen Neuroevolution - CoSyNE

“CoSyNE wurde vom Prof.Dr.Schmidhuber an der ETH Zürich entwickelt und hat damit sehr viele anderen Algorithmen in den Schatten gestellt”

“Methodik, ist wie GA bloß mit einer Aktion mehr die statt spielbare ‘Policies’, nur im Koeffizientraum entwickle”

“Dies erlaubt eine (zitat) Kooperative Entwicklung von Koeffizienten für die nachfolgenden Inv.DCT”

“Kein Crossover, geringe Mutation”

“Beispiele vom Erfolg”

2.4.1. Permutation

“Wir transponieren, shuffeln und transponieren zurück”

2.5. Cross Entropy

“Cross Entropy ist eine andere Möglichkeit um die Individuen darzustellen, anstatt von Zahlen, hab ich nun pro Coeffizient eine Normalverteilung habe mit Mean und STD”
(cite boer07)

2.5.1. Normalverteilung

“Was ist eine Normalverteilung”

“Wie programmiere ich eine Normalverteilung selber, Box-Muller, Randomness, Haskell-code Beispiel”

3. Umsetzung in RoboCup2D

RoboCup ist ein Fußball Simulator, der seine Anfänge in 1993 in Japan, Tokyo gefunden hat. Eine Gruppe von Forschern, inklusive Minoru Asada, Yasuo Kuniyoshi und Hiroaki Kitano, haben als einen Wettbewerb unter dem Namen **Robot J-League** gestartet. Der Name stammt von einer professionellen japanischen Fußball Liga.

Nach einem Monat haben sie jedoch weltweit überwältigendes Feedback bekommen und haben die Initiative als internationales Projekt weitergeführt, daher kam die Umbenennung zur **Robot World Cup Initiative**, kurz RoboCup.

Die RoboCup Initiative hat betreibt derzeit sechs große Wettbewerbe, die sich jeweils wieder in Ligen und Subligen aufteilen lassen. Darunter fällt **RoboCup Soccer**, **RoboCup Rescue Rescue**, **RoboCup Junior**, **RoboCup Logistics**, **RoboCup @ Work** und **RoboCup @ Home**. Unsere Implementierung fällt in die Subliga **2D Soccer Simulation**, in der es darum geht in einer zweidimensionalen Welt zwei Fußballmannschaften gegeneinander antreten zu lassen.

Die Aufgabe die wir behandeln gehört zu einem Fragment von RoboCup2D, genannt **Half Field Offense**.

TODO: Bild vom gesamten Spielfeld

3.1. Half Field Offense

Die Domäne Half Field Offense grenzt das Spielfeld auf genau die Hälfte ein, sodass wir 4 Angreifer und 3 Verteidiger + Torwart haben. Diese Einschränkung vereinfacht den Zustandsraum immens und erlaubt potenziell eine Wiederverwendbarkeit der Agenten, wenn eine vollständige Mannschaft aufgebaut werden muss.

In unserer Implementierung haben wir lediglich ein 1v1 Szenario, also ein Angreifer gegen ein Torwart. Diese sieht jedoch explizit ein nahtlosen Skalierung auf ein 4vs4 Szenario vor, sodass weitere Parametrisierung ohne viel Aufwand ausprobiert werden können.

TODO: BILD vom halben Spielfeld mit 1v1 Szenario

3.1.1. Zustandsraum

Im Zustandsraum der HFO Domäne kann man zwischen dem **High Level State** und dem **Low Level State** unterscheiden. Wir haben den High Level Raum benutzt. Der High Level Zustandsraum wird durch folgende Formel aufgespannt.

3. Umsetzung in RoboCup2D

Sei T die Anzahl der Teammitglieder, O die Anzahl der Gegner:

$$10 + 6T + 3O$$

TODO: Alles vom Paper abschreiben oder referenzieren?

In unserem 1v1 Setting haben wir damit 19 Zustandsparameter. Aus Angstgründen dass das Netz zu groß wird, wurden aber lediglich die *wichtigsten* 9 genommen wo ich mir gedacht habe was das mindeste an Information ist, was ein Spieler braucht um ein Tor zu schießen. Wir haben ihm folgendes gegeben:

- x Koordinaten (kontinuierlich -1 bis +1)
- y Koordinaten (kontinuierlich -1 bis +1)
- Sichtrichtung (kontinuierlich -1 bis +1)
- Nähe zum Ball (kontinuierlich 0 bis 180)
- Winkel zum Ball (kontinuierlich 0 bis 180)
- Kann eine Ballaktion (Schießen) ausgeführt werden (bool -1 oder +1)
- Wie nah bin ich am Tor dran (kontinuierlich -1 bis +1)
- Was ist der Winkel zum Mittelpunkt des Tors (kontinuierlich 0 bis 180)
- Was ist der größte offene Winkel zwischen Torwart und Torpfosten (TODO Bild) (kontinuierlich 0 bis 180)

Winkel wurden so kodiert Koordinaten wurden so kodiert Bool'sche Werten wurden so kodiert Längen Werten wurden so kodiert

Der Low Level Zustandsraum ist hat folgenden Formel (sollte das überhaupt rein?)

3.1.2. Aktionsraum

Es gibt 6 nicht parametrisierte Aktionen und 8 parametrisierte. Wir haben die nicht parametrisierten benutzt, ohne Catch, weil Angreifer den Ball nicht fangen dürfen

Parametrisierte

- Dash(power, degrees)
- Turn(degrees)
- Tackle(degrees)
- Kick(power, degrees)
- Kick_To(x-coords, y-coords, speed)
- Move_To(x-coords, y-coords)
- Dribble_To(x-coords, y-coords)

Nicht parametrisierte

- Move
- Shoot
- Dribble
- Intercept
- Catch
- No-Op

3.1.3. Einschränkungen

Diese Domäne hat viele Einschränkungen wenn man sie mit XYZ vergleicht. Zum einen erlaubt sie uns nicht in die Zukunft zu propagieren und zu schauen wie gut eine Entscheidung ist. Wir haben ausschließlich den einen Simulator zur Hand der erst nachdem ein Spiel fertig ist uns ein Fitnesssignal sendet und wir daraufhin versuchen können davon abzuleiten ob die zahlreichen Aktionen die wir ausgeführt haben uns zum Erfolg geführt

haben. Auch genannt Sparse Fitness (Probleme in anderen Domänen suchen)

Wir haben ein sog. simulation based learning (Quellen suchen)

Leider haben wir einen sehr kontinuierlichen Zustandsraum, der von uns verlangt eine Abstraktionsebene zu benutzen...NNs

Diese Art von Machine Learning von nennt man auch Black Box Reinforcement Learning

3.2. Implementierung der Algorithmen

Der ausführliche Aufbau der Algorithmen wird näher im Appendix erklärt, hier gehen wir lediglich auf die Parametrisierung und wer für was zuständig war ein.

Der Simulationsserver ist in C++ geschrieben und wurde 1-zu-1 aus (src: <https://github.com/LARG/HFO>) genommen. Er wird durch Flags beim Starten parametrisiert.

Die Agenten sind in Python geschrieben und sind eine einfache Erweiterung von einem der Beispielskripte aus (same src). Diese werden nach meiner Implementierung auch mit Kommandozeilen Flags gestartet.

Der Koordinator der für die Umsetzung des GAs zuständig ist und den Server und die Agenten Skripts startet und überwacht ist in Haskell geschrieben.

Für alle folgenden Simulationen galten die selben Rahmenbedingungen:

Generationen	300
Populationsgröße	50
Teamepisoden	25
Episodenzeit	500s
Ball nicht berührt	50s

Das heißt pro Team haben wir 25 Spiele gespielt, pro Generation 1250 und die gesamte Simulation bestand aus 375000 Spielen. Die Episodenzeit wurde auf 500 Echtzeitsekunden beschränkt, da ansonsten die simulierte Zeit pro Spiel nicht praktikabel war.

3.2.1. Wahrscheinlichkeitsverteilung von Aktionen

“Einfache Kodierung von Aktionen durch eine Wahrscheinlichkeitsverteilung, der Agent sampelt raus”

“Parametrisierung”

Der erste Algorithmus hat als Kodierung der Individuen eine diskrete Wahrscheinlichkeitsverteilung über die 5 Aktionen.

Wenn diese an den Agenten weitergegeben wurde, hat er aus dieser Verteilung gesampelt, ohne Wissen über jeglichen den Zustand.

3. Umsetzung in RoboCup2D

Die Kreuzung wurde auf zwei verschiedenen Arten umgesetzt, wobei sich keine als signifikant besser herausgestellt hatte.

Die erste Methode ...

Die zweite Methode hat beide Verteilungen genommen, die Wahrscheinlichkeiten für jeweiligen Aktionen addiert und normalisiert.

Seien \mathcal{A}, \mathcal{B} die diskreten Wahrscheinlichkeitsverteilungen die verknüpft werden sollen:

$$l := |\mathcal{A}| : \mathcal{C} := \left\{ \frac{(a_i + b_i)}{l} \mid a_i \in \mathcal{A}, b_i \in \mathcal{B} \right\}$$

Die Mutation wurde auf folgende Weise durchgeführt. δ wird in die Anzahl der Aktionen aufgeteilt, mit zufälligem Vorzeichen.

```
> splitDelta 20 5  
[-4, +4, +4, -4, -4]
```

```
> splitDelta 100 4  
[-25, +25, +25, -25]
```

Es wurde folgende Parametrisierung benutzt:

Selektion	25%
Mutationswahrscheinlichkeit	50%
Mutationsfaktor	20

3.2.2. Cross Entropy mit DCT

“Parametrisierung”

3.2.3. Neuroevolution mit DCT

“Parametrisierung”

3.2.4. CoSyNE mit DCT

“Parametrisierung”

3.3. Resultate

Im folgenden Teil finden sich alle Resultate. Durchschnittlich hat eine Trainingsphase mit 300 Generationen, Population 50 und 25 Episoden pro Team 30 Stunden gedauert. Alles wurde auf einem Laptop mit einem Intel Dualcore mit 2.9GHz und 4GB Arbeitsspeicher ausgeführt.

3.3.1. 1v1

“Domäne nochmal erklären, Zustandsraum spezifizieren, sodass alles replizierbar ist”

Wahrscheinlichkeitsverteilung

“Graph zeigen, Interpretation bzw. Erklärung” “Nach 25 Episoden stagniert”




Abbildung 3.1.: Fitness Graph zur Wahrscheinlichkeitsverteilung

Cross Entropy

“Graph zeigen, Interpretation bzw. Erklärung” “Aggressivität” “Nach 50 Episoden stagniert”

Neuroevolution

“Graph zeigen, Interpretation bzw. Erklärung”

CoSyNE

“Graph zeigen, Interpretation bzw. Erklärung”

3.3.2. Vergleich

“Sicherheit <-> Aggressivität steht im Kontra zur Stabilität der Algorithmen”

“Wenn Zeit ein Faktor wäre”

“Wenn Sicherheit ein Faktor wäre”

4. Diskussion

“Im Folgenden bespreche ich die Nützlichkeit der Ergebnisse”

4.1. Anwendungsmöglichkeiten

“Wenn starke Einschränkungen bestehen sind, waren diese Algorithmen zielführend”

4.2. Coevolutionärer Aspekt

“Die Annahmen für Netze zu treffen ist interessant gewesen, hat anscheinend auch für 30k Gewichte geklappt, sollte man später zum checken”

4.3. Ausblick

“Im Folgenden gebe ich meinen Senf zu den Parametrisierungen an und wenn die Welt perfekt wäre, was ich dann machen würde”

4.3.1. Genetische Algorithmen

“Hab nicht an den Parameteren gespielt”

4.3.2. Aufbau des neuronalen Netzes

“Hab nicht verschiedene Netze ausprobiert”

4.3.3. Cross Entropy

“Hab die naivste Implementierung genommen, könnte viel viel besser werden, wenn man Grips reinsteckt”

4.3.4. Aktionsraum

“Hätte bessere Aktionen definieren können, die schlauere Spielzüge erlauben, da ich die Vermutung habe dass die jetzigen ein Hardcap an Qualität bieten”

4.3.5. Multi-Agenten Systeme

“Hatte noch keine Möglichkeit in diese Domäne ausführlich zu testen”

4.4. Verwandte Felder

“Folgende Reads sind nice”

4. Diskussion

4.4.1. Implementierung für OpenAI Gym

“Update für OpenAI Gym, meine Implementierung wird folgen”

“Keine Multi-Agenten Setting möglich, dsw ist meine Arbeit nicht umsonst gewesen”

4.4.2. Bestärkendes Lernen - Black Box RL

“Wenn man die Netze als Policy betrachtet ist meine Arbeit eine Anwendung im Reinforcement Learning Bereich gewesen”

4.4.3. Convolutional neuronale Netze und CoSyNE

“Warum ist die Annahme für homogene Netzstrukturen besser für Convolutional Networks”

“Evtl ist CoSyNE dort richtig geil”

Roboterarm

“Bilder, Graphen und Parametrisierung zeigen + Link + Zitat”

Rennspiel

“Bilder, Graphen und Parametrisierung zeigen + Link + Zitat”

A. Appendix

“Da der Fokus sehr stark auf dem Machine Learning Bereich lag, aber die Domäne viele Tücken hatte und die Implementierung einen Großteil der Zeit in Anspruch genommen hat, wird es hier behandelt”

A.1. Architektur

“Die Architektur des gesamten Projektes wurde in Haskell geplant, da ich mit externen und unsicheren Implementierungen arbeite”

“Automatische Docs, weil ich gute Kommentare schreibe” “Hat geholfen Fehler schneller zu finden und Codereuse ist super geil gewesen”

“Bild von der Kommunikation zeichnen”

A.1.1. Haskell Server

“Module”

“Typklassen sind geil”

“Globale Config ist nice”

“Automatische Serialisierung mit Aeson”

A.1.2. Python Agent

“Module”

“CMD Parser”

“Keras”

A.1.3. Kommunikation

“Haskell <-> Python: JSON ist von Python nativ als Dict unterstützt” “Python <-> Server: FFI Python to C++ (HFO) + (Zitat)”

A.1.4. Parallelisierungsmöglichkeiten

“Bottleneck ist die Kommunikation über JSON-Files”

A.2. Statistik

“Für Cross Entropy hab ich Varianz und STD mit Seed gebraucht, für MonadRandom gabs keine Implementierung, dsw hab ich eine eigne gemacht”

A.2.1. Lineares Laufzeit und Speicherkomplexität für Evaluation

“Folds sind supernice, minimale Erklärung, Links zu Gabriels Blog, Vorzeigen von Effizienz”

A.2.2. Stabile Varianzfunktion

“Catastrophic Cancellation, erste Lösung, zweite Lösung von Gabriel mit E-Mail Austausch”

A.3. Problematiken

“Server ist scheiße, nicht besonders gut dokumentiert”

A.3.1. HFO Server

“Erfolgreicher Durchlauf ist abhängig vom Computer, bzw. von der Leistung”

“Undefinierte Lags zwischen Step 2k-8k”

“Bedienung vom Visualizer ist nicht richtig erklärt”

“Visualizer produziert nicht benutzbare logs, nur das erste Spiel ist ‘abspielbar’, rest ist korrupt ”

“Einloggen von Spielern nimmt sehr viel Zeit in Kauf, dafür muss ein Austausch von Policies on-the-fly passieren”

“Visualizer bricht bei 24k Steps ab, aber ohne ihn funktioniert die Simulation nicht, laggt nur rum”

“Es gibt keine Zeitangaben wie lange ein Agent nicht aktiv sein darf, wenn er keine Entscheidung abgibt wird er ignoriert, dieser Fall sollte behandelt werden für kompetative Benutzung”

A.3.2. HFO Python Library

“Kodierung von Zuständen in denen sich der Agent befindet gibt ein Hexdump zurück, man muss per Hand die ENUMS herausfinden und hardcoden”